



VERİ MADENCİLİĞİ PROJE İLERLEME RAPORU
(Project Outline Report)

Ders : FET445 - Veri Madenciliği

Konu: İkinci El Araç Fiyat Tahminlemesi (Car Price Prediction)
Bölüm: Yazılım Mühendisliği

Grup: 1.6Multijet

Grup Üyeleri

İsim Soyisim	Numara	E-Mail
Ramazan Bozkurt	22040301027	ramazannbozkurrtt@outlook.com
Ömer Utku Aktemur	22040301043	aktemurutku@gmail.com
Erkan Yasin Yaman	22040301038	erkan.yasin00@gmail.com

Repo Link: <https://github.com/RamazanBozkurrtt/1.6Multijet-DataMiningProject-Final>

2. Problem Tanımı

- **İş/Bilimsel Soru:** İkinci el araç piyasasında fiyatlar; marka, model, yıl, motor hacmi, yakıt tipi ve kilometre gibi birçok değişkene bağlı olarak şekillenmektedir. Bu projenin temel sorusu şudur: "Bir aracın teknik özellikleri ve kullanım geçmişi bilindiğinde, makine öğrenmesi algoritmaları aracın adil piyasa değerini ne kadar düşük bir hata payı ile tahmin edebilir ve araçlar teknik özelliklerine göre hangi doğal pazar segmentlerine (kümelere) ayrılır?"
- **Görev Türü :**
 - **Regresyon(Prediction):** Araç fiyatının sayısal tahmini.
 - **Kümeleme(Clustering):** Araçların özelliklerine göre segmentlere ayrılması.
- **Hedef Değişken:** Price (Araç Fiyatı)
 - **Birim:** GBP (£)
 - **Etki Alanı:** Sürekli sayısal değişken (Pozitif tam sayı)
- **Başarı Kriterleri:**
 - Modelin açıklayıcılık katsayısı (R^2 Score) ≥ 0.85
 - Hata Kareler Ortalamasının Karekökü (MAE) değerinin minimize edilmesi.

3. Proje Yönetimi

Kilometre Taşları ve Zaman Çizelgesi:

- 1. Hafta : Veri seti seçimi (Kaggle - UK Used Car Dataset) ve literatür taraması. (Tüm Grup)
- 2. Hafta : Veri birleştirme, temizleme ve Keşifsel Veri Analizi (EDA).
- 3. Hafta: Eksik veri stratejisinin belirlenmesi ve uygulanması ve her üyenin kendi belirlediği 2 farklı Base Model ve 1 Kümeleme Algoritması ile model geliştirme süreçleri. (Bireysel Çalışmalar)
- 4. Hafta: Performans analizi, modellerin RMSE/R2 skorlarının karşılaştırılması ve en iyi modelin seçimi. Proje raporunun ve sunumun hazırlanması.

Roller ve Sorumluluklar:

- **Ramazan Bozkurt:**
 - Kümeleme: Agglomerative Clustering (Hiyerarşik Kümeleme)
 - Modeller: KNN Regressor, Decision Tree Regressor, GradientBoostRegressor, StackingRegressor
- **Erkan Yasin Yaman:**
 - Kümeleme: K-NN Clustering
 - Modeller: Linear Regression ve Lasso Regression(Threshold,Scaling)
- **Ömer Utku Aktemur:**
 - Kümeleme: K-Means Clustering

- Modeller: Ridge Regression, Support Vector Regression (SVR), AdaBoostRegressor, VotingRegressor

Çıktılar:

- Final Proje Raporu (PDF)
- Jupyter Notebook Kod Dosyaları
- Temizlenmiş Veri Seti
- Temizlenmiş ve Kümelenmiş Veri Seti

4. İlgili Çalışmalar (Mini Literatür İncelemesi)


- **Referans 1:** Pudaruth, S. (2014). "Predicting the Price of Used Cars using Machine Learning Techniques". Bu çalışmada yazar, KNN, Çoklu Doğrusal Regresyon ve Karar Ağaçlarını karşılaştırmış, Karar Ağaçlarının en iyi sonucu verdiğini belirtmiştir.
- **Referans 2:** Gegic, E. et al. (2019). "Car Price Prediction using Machine Learning". Yapay Sinir Ağları ve Random Forest kullanılarak %90 üzeri başarı elde edilmiştir.
- **Karşılaştırma ve Farkımız:** Mevcut literatürde genellikle eksik veriler ortalama ile doldurulup geçilmektedir. Bizim projemizin farkı, eksik kategorik verileri (Marka/Model) basit yöntemler yerine "Decision Tree Classifier" kullanarak diğer teknik özelliklerden tahmin edip doldurmamızdır (Smart Imputation). Ayrıca Feature Selection (SelectKBest) yönteminin, Boyut İndirgeme (PCA) yöntemine göre temel modeller üzerindeki etkisi spesifik olarak incelenmiştir.

5. Veri Tanımı ve Yönetimi

- **Veri Seti:** "100,000 UK Used Car Data set" (Kaggle). Audi, BMW, Ford, VW gibi markaların verileri birleştirilmiştir.
- **Bağlantı:** <https://www.kaggle.com/datasets/adityadesai13/used-car-dataset-ford-and-mercedes>
- **Veri Şeması:**
 - model, transmission, fuelType: Kategorik (String)
 - year, mileage, tax, mpg, engineSize: Sayısal (Float/Int)
 - price: Hedef Değişken (Integer)
- **Boyut:** Orijinal veri setinde 100.000'den fazla satır bulunmaktadır. Ancak projenin hesaplama verimliliği açısından, tüm markaları kapsayan 30.000 satırlık rastgele ve tekrarlanabilir (random_state=42) bir örneklem oluşturulmuştur. 10 Sütun (9 Orijinal özellik + 1 Türetilmiş brand özelliği). (30.000x10)
- **Veri Erişim Planı:** Veriler CSV formatında GitHub deposunda saklanmaktadır.
- **Etik ve Gizlilik:** Veri seti halka açık (public domain) olup, kişisel tanımlayıcı bilgi (isim, plaka, şasi no) içermemektedir. Önyargı riski olarak, veri seti sadece İngiltere pazarını kapsadığı için modeller Türkiye pazarında doğrudan kullanılamayabilir.

6. Keşifsel Veri Analizi (Exploratory Data Analysis)

- **Veri Kalitesi:** tax, tax(£) ve mileage, mileage2 gibi tekrar eden ve eksik sütunlar tespit edilmiştir.
- **Dağılımlar:** Hedef değişken price sağa çarpık (right-skewed) bir dağılım göstermektedir (Az sayıda çok pahalı araç, çok sayıda orta segment araç).
- **İlişkiler:** car_age (Araç yaşı) ile price arasında güçlü negatif korelasyon, engineSize ile price arasında pozitif korelasyon gözlemlenmiştir.



7. Veri Hazırlama Planı

Bu bölümde, grup üyelerinin veri hazırlama aşamasında uyguladıkları ortak ve farklılaşan (bireysel) stratejiler detaylandırılmıştır.

7.1. Ortak Temizlik İşlemleri

- **Temizleme:** Farklı isimlerdeki benzer sütunlar (tax ve tax(£)) birleştirilip (fillna) tekilleştirilmiştir.
- **Özellik Mühendisliği:** year değişkeninden car_age (Araç Yaşı) türetilmiştir.

7.2. Bireysel Ayırışma Noktaları (Differentiation Points)

A. Ramazan Bozkurt'un Yaklaşımı:

- **Veri Temizleme ve Kalite Kontrolü (Data Cleaning):**
 - Regex ile Veri Tipi Düzeltme: Price ve Mileage sütunlarındaki para birimi sembolleri (£,(,)) Regex ile temizlenerek veriler sayısal formata dönüştürülmüştür.
 - Sütun Standardizasyonu: Yazım tutarsızlıklarını gidermek için tüm sütun adları standartlaştırılmış ve özel karakterlerden arındırılmıştır.
 - Gereksiz Sütunların Atılması: Tekrarlayan veya analize gürültü katan sütunlar (reference, tax_gbp vb.) veri setinden çıkarılmıştır.

- **Hedef Değişken Temizliği:** Hedef değişken olan price sütununda eksik veya hatalı veri bulunan satırlar, eğitim sürecini bozmaması adına veri setinden silinmiştir.
- **İmputasyon Stratejisi (Eksik Veri Tamamlama):**
 - Birleştirme (Coalesce) Mantığı: Farklı sütunlara dağılmış benzer veriler (mileage varyasyonları) birleştirilerek veri kaybı önlenmiştir.
 - Model Tabanlı İmputasyon (Kategorik): Basit "Mod" yöntemi yerine, veri setindeki desenleri öğrenen bir Decision Tree Classifier kullanılmıştır.
 - İstatistiksel İmputasyon (Sayısal): Sayısal eksik veriler, aykırı değerlerden etkilenmemesi amacıyla Medyan (Ortanca) stratejisi ile doldurulmuştur.
- **Veri Dönüşümü (Transformation) ve Kodlama:.**
 - One-Hot Encoding: KNN ve Decision Tree modellerinin kategorik veriyi işleyebilmesi için Marka, Model gibi değişkenler One-Hot Encoding ile sayısal matrislere dönüştürülmüştür.
 - Ölçekleme (Scaling) Deneyi (A/B Testi): Mesafe temelli KNN için zorunlu olan StandardScaler'ın etkisi (Ham Veri vs. Ölçekli Veri) deneysel olarak test edilmiş ve Karar Ağaçlarının ölçekten bağımsız çalıştığı kanıtlanmıştır.
- **Özellik Mühendisliği (Feature Engineering) ve Zenginleştirme:**
 - Hiyerarşik Kümeleme ile Özellik Türetimi (Agglomerative Clustering): Araçların gizli pazar segmentlerini (Lüks, Ekonomik) keşfetmek için Agglomerative Clustering uygulanmış; elde edilen küme etiketleri (segment_cluster), regresyon modellerine yeni bir öznitelik olarak eklenmiştir.
 - Amaç: Modelin, "Lüks", "Ekonomik", "Spor" gibi gizli pazar segmentlerini öğrenmesini kolaylaştırmak.
 - Uygulama: Küme etiketleri (segment_cluster), regresyon modellerinin fiyat tahminini iyileştirmesi için girdi değişkeni olarak kullanılmıştır.
 - Alan Bilgisi (Domain Knowledge): Araçların üretim yılı (year) yerine, ikinci el piyasasındaki değer kaybını (depreciation) daha iyi ifade eden Araç Yaşı (car_age) özelliği türetilmiştir.
- **Özellik Seçimi (Feature Selection):**
 - Filter Method: Modelin yorumlanabilirliğini korumak adına Filter Method (SelectKBest, k=15) uygulanmıştır.
 - Gözlem: Bu işlemin, veri setinin yüksek bilgi yoğunluğu nedeniyle bazı senaryolarda Bilgi Kaybı yaratarak model performansını düşürdüğü gözlemlenmiştir

B. Erkan Yasin Yaman'ın Yaklaşımı:

- Variance Threshold (Varyans Eşiği): PCA gibi veriyi dönüştürmek yerine, ayırt ediciliği düşük olan (varyansı 0.01'in altındaki) özellikleri eleyerek modelin karmaşıklığı azaltılmıştır.
- k-NN ile Özellik Mühendisliği (Clustering-based Feature Engineering): Projenin en yenilikçi adımıdır. Gözetimsiz öğrenme mantığıyla çalışan k-Nearest Neighbors (k-NN) algoritması kullanılarak araçlar fiziksel özelliklerine göre *Ekonomik*, *Orta* ve *Lüks* olmak üzere 3 segmente ayrılmıştır. Bu "Tahmini Segment" bilgisi, regresyon modellerine yeni bir öznitelik (feature) olarak eklenmiştir.
- Feature Scaling (Ölçekleme): Özellikle Lasso Regresyon ve k-NN mesafe tabanlı çalıştığı için, veri StandardScaler ile ölçeklenmiştir.

İki farklı regresyon algoritması (Linear & Lasso), 4 farklı senaryoda test edilmiştir:

- **A. Linear Regression: Temel regresyon modelidir.**
 - *Senaryo*: Saf Hali, Sadece Threshold, Sadece Kümeleme ve Full Paket (Threshold + Kümeleme).
 - *Sonuç*: Saf model %77 başarı gösterirken, k-NN segmentasyonu eklendiğinde R^2 skoru %78.16'ya yükselmiştir.
- **B. Lasso Regression (L1 Regularization): Özellik seçimi yapabilen, gereksiz katsayıları sıfırlayan modeldir.**
 - *Senaryo*: Saf Hali (Başarısız), Scaling + Threshold (Standart) ve Hibrit Model (Scaling + Threshold + k-NN Segmentasyon).
 - *Sonuç*: Ölçeklenmemiş veride başarısız olan Lasso, hibrit yapıda kullanıldığında Linear Regression ile yarışır bir performans sergileyerek yüksek başarı oranlarına ulaşmıştır.

C. Ömer Utku Aktemur'un Yaklaşımı:

1. Veri Dönüşümü ve Ölçekleme:

- Kullandığım uzaklık ve varyans temelli modellerin (Ridge, SVR, K-Means, PCA) hassasiyeti nedeniyle veri setine StandardScaler uygulanması zorunlu tutulmuştur. Kategorik değişkenler, sınıf sayılarına göre Label Encoding (model sütunu) ve One-Hot Encoding ile sayısal hale getirilmiştir.

2. Boyut İndirgeme (PCA):

- Özellik seçimi yerine, değişkenler arasındaki çoklu bağlantı (multicollinearity) sorununu çözmek için PCA tercih edilmiştir. Veri setindeki varyansın %95'ini koruyacak şekilde boyut indirgeme uygulanmıştır.

3. Deneysel Tasarım (4 Senaryo):

- Farklı tekniklerin performans etkisini ölçmek için modeller 4 aşamalı test edilmiştir:
- Base Model: Standartlaştırılmış ham veri (Referans).
- Sadece PCA: Gürültüsü azaltılmış ve boyutu indirgenmiş veri.
- Kümeleme Destekli: Ham veriye "Pazar Segmenti" bilgisinin eklendiği veri.

- Hibrit (PCA + Kümeleme): Hem boyutun indirgendiği hem de segmentasyon bilgisinin eklendiği en gelişmiş yapı.

8. Modelleme Planı

Bu bölümde, geliştirilen temel modellerin performans sonuçları, geliştiricilerine göre ayrılmıştır.

8.1. Baseline (Referans) Model Stratejisi

Modellerin başarısını ölçümleyebilmek için öncelikle bir "Dumb Baseline" stratejisi belirlenmiştir.

- Strateji: Veri setindeki ortalama fiyatı (Mean) tahmin eden basit bir yaklaşım referans noktası olarak kabul edilecektir. Geliştirdiğimiz modellerin bu referans noktasından ve birbirlerinden ne kadar iyi performans gösterdiği analiz edilecektir.

8.2. Aday Modeller ve Seçim Gerekçeleri

Grup üyeleri, veri setindeki farklı yapıları (doğrusal ve doğrusal olmayan ilişkiler) test etmek amacıyla farklı algoritmalar seçmiştir

A. Ramazan Bozkurt – KNN, Decision Tree, GradientBoost ve StackingRegressor Analizi

Baseline Model:

- Projede "Scale Yok (Ham Veri)" senaryosu, yinelemeli (iterative) model geliştirme sürecinin başlangıç noktası ve Baseline (Taban) Model olarak kurgulandı. Parametre optimizasyonu yapılmadan kurulan bu saf modeller, ileri ön işleme tekniklerinin (Scaling, Kümeleme, Feature Selection) modele katkısını ölçmek için referans noktası oldu.


Aday Modeller :

1. K-Nearest Neighbors (KNN) Regressor:

- Neden: Araç piyasasında fiyat belirleme mantığı genellikle "benzer araçların fiyatına bakma" ilkesine dayanır. KNN, mesafe tabanlı yapısıyla bu "benzerlik" ilkesini en iyi simüle eden algoritmadır.

Performans Tablosu:


Model	KÜMELEME	Veri Durumu	MAE (Ort. Hata)	R2 Score (Başarı)
KNN	YOK	Scale Yok (Ham Veri)	5488.283394	0.368714
KNN	YOK	Scale Var (Tum Ozellikler)	1412.279433	0.937450
KNN	YOK	Feature Selection (Top 15)	1853.360901	0.891799
KNN	VAR	Scale Yok (Ham Veri)	5441.806468	0.378018
KNN	VAR	Scale Var (Tum Ozellikler)	1420.301926	0.937124
KNN	VAR	Feature Selection (Top 15)	1845.232304	0.891975



2. Decision Tree (Karar Ağacı) Regressor:

- Neden:** Verisetindeki doğrusal olmayan (non-linear) ilişkileri yakalayabilmesi ve if-then kuralları ile insan tarafından yorumlanabilir (interpretable) sonuçlar üretmesi nedeniyle tercih edilmiştir.
- Yapısal Tercih :** Bu çalışmada kullanılan Karar Ağacı, varsayılan (default) ayarların aksine, aşırı öğrenmeyi (overfitting) engellemek ve modelin genelleme yeteneğini artırmak amacıyla sınırlandırılmıştır (Pruning). Ağacın sonsuz derinleşmesine izin verilmemiş, derinlik (max_depth) ve yaprak başına düşen örnek sayısı (min_samples_leaf) optimize edilerek kontrol altında tutulmuştur.
- Performans Tablosu:**


Model	KÜMELEME	Veri Durumu	MAE (Ort. Hata)	R2 Score (Başarı)
Decision Tree	YOK	Scale Yok (Ham Veri)	2072.299491	0.889252
Decision Tree	YOK	Scale Var (Tum Ozellikler)	2073.177752	0.889192
Decision Tree	YOK	Feature Selection (Top 15)	2160.075671	0.877114
Decision Tree	VAR	Scale Yok (Ham Veri)	2114.905589	0.887193
Decision Tree	VAR	Scale Var (Tum Ozellikler)	2117.165627	0.886859
Decision Tree	VAR	Feature Selection (Top 15)	2224.584477	0.866883



3. Gradient Boosting Regressor (GBR)

- **Neden:** GBR, hataları adım adım optimize eden (boosting) bir yapıya sahiptir. Karar ağaçlarını ardışık olarak kurarak, bir önceki ağacın yaptığı hataları minimize etmeye odaklanır. Araç fiyatlarındaki çok değişkenli ve non-linear yapıyı KNN'den daha hassas yakalaması beklenmiştir.
- **Performans Analizi :**

Model	Seneryo	R2 Skoru	MAE(GBP)	R2 Score (Başarı)	RMSE (GBP)	Süre (sn)
GBR	Standart GBR	9.612	1273.04	2088.29	142.96	9.612
GBR	GBR + K-means	9.601	1295.54	2173.51	154.55	9.601
GBR	GBR + Agglomerative	9.620	1275.15	2089.60	178.93	9.620




4. Stacking Regressor (Meta-Model)

- **Neden:** Farklı modellerin (örneğin KNN, DT, GBR) tahminlerini girdi olarak kullanan bir "meta-model" eğiterek, her bir algoritmanın güçlü yönlerini birleştirmeyi amaçlar. "Bilgelerin Meclisi" mantığıyla çalışır.
- **Performans Analizi :**

Model	Seneryo	R2 Skoru	MAE(GBP)	R2 Score (Başarı)	RMSE (GBP)	Süre (sn)
SR	Base Stacking	9.613	1302.32	9.613	2176.76	35.62
SR	Stacking + K-means	9.606	1312.41	9.606	2191.73	43.56
SR	Stacking + Agglo.	9.614	1297.53	9.614	2152.17	58.23

Stacking Regressor: Kümeleme Tekniklerinin Başarı Karşılaştırması (R2 Skoru)



• Değerlendirme ve Analiz:

- Genel Başarı ve Model Seçimi: Yapılan kapsamlı deneylerde KNN (Scale Var - Tüm Özellikler) senaryosu 0.937 R2 skoru ile en yüksek başarıyı göstermiştir. KNN algoritmasının yerel benzerlikleri yakalamadaki başarısı, araç fiyatlandırma probleminin doğasıyla tam uyum sağlamıştır.
- Ölçeklemenin Kritik Etkisi:
 - KNN İçin: Ölçekleme yapılmadığında 0.36 gibi çok düşük bir R2 skoru veren KNN, StandardScaler uygulandığında başarıyı 0.93 seviyesine yükseltmiştir. Bu durum, mesafe temelli modellerin kanıtıdır.
 - Decision Tree İçin: Karar Ağaçlarının verinin ölçeğinden bağımsız (scale-invariant) çalıştığı doğrulanmıştır (Scale Var/Yok R2 skoru ~0.88).

- Kümeleme (Clustering) Etkisi ve Redundancy: Agglomerative Clustering ile üretilen Cluster ID bilgisinin eklenmesi, performansta belirgin bir artış sağlamamıştır. Bunun nedeni, küme bilgisinin temel özellikler (Yıl, Motor, KM) tarafından zaten açıklanabilmesi ve bu bilginin model için yüksek korelasyonlu (redundant) kalmasıdır. Bu, DT'nin ham veriyi ezberlemeden en iyi kuralı bulduğunu göstermiştir.
- Decision Tree Regression Üzerinde Scale ve Kümelemenin negatif etkili olması nedeni
 - Sonuç: Bu deney, Decision Tree modelinin ham veri (Raw Data) üzerindeki karmaşık ilişkileri yakalamada zaten oldukça yetenekli olduğunu ve bu veri seti özelinde ekstra özellik mühendisliğine (Feature Engineering) ihtiyaç duymadığını kanıtlamıştır. En saf ve yalın model (Ham Veri), en iyi sonucu vermiştir.
- Hiper-Parametre Ayarlama:

Modellerin temel performansını ölçmek adına aşağıdaki parametre konfigürasyonları kullanılmıştır:



 - KNN: Komşu sayısı $n_neighbors=5$ olarak belirlenmiştir.
 - Decision Tree (Özelleştirilmiş - pruning):
 - Modelin ezberlemesini önlemek için $max_depth=10$ (Maksimum derinlik) olarak sınırlandırılmıştır.
 - Gürültülü veriye aşırı duyarlılığı azaltmak için $min_samples_leaf=4$ (Bir yaprakta olması gereken minimum örnek) olarak ayarlanmıştır.
 - Bölünme kriteri için $min_samples_split=10$ kullanılmıştır.
 - Feature Selection: Seçilecek özellik sayısı $k=15$ olarak sabitlenmiştir.
- Sınıf Dengesizliği Stratejisi (Class Imbalance):
 - Sınıf Dengesizliği Stratejisi: Proje Regresyon problemi olduğundan, Sınıf Dengesizliği kavramı teknik olarak geçerli değildir. Ancak, fiyat dağılımındaki aşırı uç değerler, Akıllı Eksik Veri Doldurma ve Standardizasyon teknikleri kullanılarak kontrol altında tutulmuştur
- GBR, tekil Karar Ağacı (0.88) ve KNN (0.93) modellerini geride bırakarak şu ana kadarki en yüksek doğruluğa ulaşmıştır. Agglomerative Clustering entegrasyonu, KNN'de olduğunun aksine GBR'da çok küçük de olsa pozitif bir katkı sağlamıştır.
- Raporun başındaki Baseline modelden ($R^2: 0.36$) başlayarak, önce ölçekleme ($R^2: 0.93$) ve son olarak Ensemble yöntemlerle ($R^2: 0.96$) devam eden süreç, veri madenciliği döngüsünün (CRISP-DM) başarısını kanıtlamaktadır. GBR, hem hız hem de hata payı (MAE) bakımından en dengeli model olarak öne çıkmaktadır.
- Önceki analizinde belirttiğin "redundancy" (gereksizlik) durumu burada da büyük oranda geçerli. Ancak Agglomerative Clustering'in, K-means'e göre hem GBR hem de

Stacking üzerinde daha tutarlı sonuçlar vermesi dikkat çekicidir. Bu durum, verisetindeki gruplanmaların dairesel (spherical) değil, hiyerarşik bir yapıda olduğuna işaret eder

- Stacking modelinde yaklaşık 53.745 GBP'lik bir maksimum hata payı görülmektedir. Bu, verisetinde hala "nadir bulunan antikalar" veya "hasarlı lüks araçlar" gibi genel trendin çok dışında kalan uç değerlerin (outliers) bulunduğunu, modelin bu uç noktaları tahminlemede zorlandığını göstermektedir.

B. Erkan Yaman - Linear Regression ve LassoRegresyon Analizi

- Geliştirilen Modeller: Linear Regression ve Lasso Regression(Threshold,Scaling)**
- Kullanılan Kümeleme: k-NN Clustering**



C. Random Forest Regressor Yaklaşımı (Ensemble - Bagging)

Doğrusal modellerin (Linear & Lasso) performansının %78 bandında doyum noktasına ulaşması ve veri setindeki doğrusal olmayan (non-linear) ilişkileri yakalamakta yetersiz kalması üzerine, Topluluk Öğrenmesi (Ensemble Learning) yöntemlerinden biri olan Random Forest algoritmasına geçilmiştir.

1. Metodoloji ve Yaklaşım:

- **Bagging (Bootstrap Aggregating):** Tek bir karar ağacının (Decision Tree) veriyi ezberleme (overfitting) eğilimini kırmak amacıyla, 100 adet bağımsız karar ağacı paralel olarak eğitilmiştir. Her bir ağaç, veri setinin farklı alt kümeleri üzerinde eğitilmiş ve nihai tahmin, bu ağaçların ortalaması alınarak oluşturulmuştur.
- **Feature Importance (Özellik Önem Düzeyi):** Modelin sunduğu Gini Importance metriği sayesinde, fiyatı etkileyen faktörler matematiksel olarak doğrulanmıştır. Yapılan analizde Üretim Yılı (Year) ve Motor Hacmi (EngineSize) değişkenlerinin fiyat üzerindeki varyansın büyük kısmını açıkladığı görülmüştür.

2. Senaryo Bazlı Analiz ve Sonuçlar: Model, aşağıdaki 4 farklı veri ön işleme senaryosu ile test edilmiştir:

- **Ham Veri (Baseline):** Herhangi bir eleme yapılmadan tüm özellikler kullanıldı. (R^2 : %93.62)
- **Sadece Threshold:** Varyansı 0.01 altındaki durağan özellikler çıkarıldı. (R^2 : %92.47)
- **Sadece Kümeleme:** Araçlar özelliklerine göre segmente ayrılıp etiketlendi. (R^2 : %93.41)
- **Hibrit Model:** Hem gereksiz özellikler atıldı hem de segment bilgisi eklendi. (R^2 : %92.47)

Değerlendirme: Linear modellerin aksine Random Forest, veri setindeki karmaşık örüntüleri başarıyla çözerek R^2 skorunu %90'ın üzerine taşımıştır. Ham veri en yüksek başarıyı verse de, Hibrit Senaryo (Threshold + Kümeleme), veri boyutunu azaltmasına rağmen performanstan ödün vermeyerek (%92.47) daha optimize ve hızlı bir model yapısı sunmuştur. Modelin MAPE (Ortalama Mutlak Yüzde Hata) değeri %8.6 - %9.6 aralığına inmiştir; bu da modelin gerçek piyasa koşullarında %10'un altında bir yanılma payı ile güvenilir tahminler ürettiğini kanıtlamaktadır.

D. HistGradientBoosting Regressor Yaklaşımı (Ensemble - Boosting)

Projenin en Gelişmiş aşaması olarak, büyük ölçekli ve heterojen veri setlerinde yüksek performans gösteren Histogram-Based Gradient Boosting algoritması tercih edilmiştir.

1. Neden Seçildi? (Teknik Altyapı):

- **Histogram Binning (Kutulama):** Klasik Gradient Boosting algoritmaları (XGBoost, GBM) her düğümde (split) tüm veriyi sıralamaya çalışırken zaman kaybeder. HistGradientBoosting ise sürekli değişkenleri (fiyat, mil vb.) 256 adet tamsayı kutusuna (bins) ayırarak (discretization) işlem yapar.
- **Hız ve Verimlilik:** Bu kutulama tekniği sayesinde, 30.000 satırlık veri setimizde eğitim süresi dakikalardan saniyeler seviyesine inmiştir.

2. Senaryo Performansı ve "Kümeleme" Etkisi: Bu modelde Sadece Kümeleme (Senaryo3) yaklaşımı, diğer tüm senaryoları geride bırakarak projenin zirve noktasını oluşturmuştur.

- **En İyi Sonuç (Best Model):** %92.10 R^2 skoru ile "Sadece Kümeleme" senaryosu.
- **Hata Oranları:** RMSE değeri 2758 birime, MAE değeri ise 1621 birime kadar düşürülmüştür. Bu değerler, Linear modellere kıyasla hatanın neredeyse yarı yarıya azaldığını göstermektedir.





Değerlendirme: HistGradientBoosting, özellikle k-NN/K-Means ile ürettiğimiz "Tahmini Segment" bilgisini (Cluster Label) çok verimli kullanmıştır. Bu yeni özellik, boosting algoritmasının ağaçları oluştururken daha doğru ayırım noktaları (split points) bulmasına yardımcı olmuş ve modelin tahmin kararlılığını artırmıştır.

E. Genel Değerlendirme ve Sonuç

Bu çalışmada geliştirilen 4 farklı algoritma ve uygulanan 4 farklı Özellik Mühendisliği (Feature Engineering) senaryosu sonucunda elde edilen temel bulgular şunlardır:

1. **Algoritma Seçiminin Önemi:** Doğrusal modeller (Linear/Lasso) veriyi genel hatlarıyla açıklayabilse de (%78 R^2), araç fiyatlarındaki ince detayları ve doğrusal olmayan ilişkileri yakalamakta yetersiz kalmıştır. Ağaç tabanlı modellere (Tree-Based Models) geçiş yapılması, başarı oranını %15 puanlık dramatik bir artışla %93 seviyelerine taşımıştır.
2. **Öznitelik Mühendisliğinin (Feature Engineering) Katkısı:** Önerdiğimiz "Kümeleme Tabanlı Öznitelik Mühendisliği" (Clustering-based Feature Engineering) yaklaşımı projenin başarısında kilit rol oynamıştır.
 - Araçları fiziksel özelliklerine göre *Ekonomik*, *Orta* ve *Lüks* gibi gizli segmentlere ayıran bu yapı, modellere ekstra bir bilgi katmanı sağlamıştır.
 - Özellikle HistGradientBoosting modelinde bu özellik, ham veriye kıyasla performansı artırmış ve modelin araçları daha iyi tanımasını sağlamıştır.

3. **Sonuç:** Elde edilen %9.6 MAPE (Ortalama Yüzde Hata) ve 0.93 R^2 değerleri, geliştirilen modelin ikinci el araç fiyat tahminlemesi probleminde yüksek güvenilirlikte ve ticari olarak kullanılabilir seviyede olduğunu göstermektedir. Hibrit yapı (Threshold + Kümeleme), veri setini temizleyip zenginleştirerek, hem hızlı hem de başarılı bir tahmin mimarisi oluşturmuştur.



C. Ömer Utku Tarafından Geliştirilen Modeller:

Veri setindeki hem doğrusal hem de karmaşık ilişkileri kapsamak amacıyla aşağıdaki 5 model seçilmiştir:

1. Ridge Regresyon (Doğrusal Model):

- **Seçim Nedeni:** Değişkenler arasındaki çoklu bağlantı (multicollinearity) sorununu aşmak ve L2 regularizasyonu ile aşırı öğrenmeyi (overfitting) engellemek için tercih edilmiştir.
- **Beklenti:** Fiyat üzerindeki doğrusal etkileri hızlı ve kararlı bir şekilde modellemesi hedeflenmiştir.

2. SVR - Destek Vektör Regresyonu (Kernel Tabanlı Model):

- **Seçim Nedeni:** Ridge modelinin yakalayamadığı doğrusal olmayan (non-linear) karmaşık fiyat desenlerini, RBF çekirdeği kullanarak modellemek için seçilmiştir.
- **Beklenti:** Büyük veri setlerinde eğitim maliyeti yüksek olsa da, PCA desteği ile karmaşık yapılarda en yüksek başarıyı göstermesi beklenmektedir.

3. K-Means (Kümeleme):

- **Seçim Nedeni:** Fiyat tahmininden bağımsız olarak, araçları teknik özelliklerine göre pazar segmentlerine (Ekonomik, Orta, Lüks) ayırmak için kullanılmıştır.
- **Beklenti:** Verinin gizli yapısını ortaya çıkarmak ve elde edilen "Segment Bilgisini" tahmin modellerine ek bir öznitelik olarak sunmaktır.



4. AdaBoostRegressor:

- **Seçim Nedeni:** Standart regresyon modellerinin yakalamakta zorlandığı, veri setindeki uç değerleri (outliers) ve karmaşık fiyatlandırma davranışlarını "Hata Odaklı" (Error-Centric) bir yaklaşımla öğrenmek için seçilmiştir.
- **Beklenti:** Zayıf öğrenicileri (Karar Ağaçları) birbirinin hatasını düzeltecek şekilde ardışık (sequential) olarak eğitmek ve bu sayede modelin özellikle öğrenilmesi güç olan "zor" örneklerdeki hata payını minimize ederek genel başarıyı (R^2) artırmaktır.

5. Voting Regressor (Oylama Regresyonu):

- **Seçim Nedeni:** Tek bir algoritmanın veriye bakış açısına (Bias) bağımlı kalmamak ve farklı matematiksel altyapıya sahip modellerin (Ridge, SVR, Extra Trees) "Ortak Akıl" (Wisdom of the Crowd) prensibiyle karar vermesini sağlayarak tahmin güvenilirliğini artırmak için seçilmiştir.
- **Beklenti:** Doğrusal (Linear) ve doğrusal olmayan (Non-linear) modellerin tahminlerini ağırlıklı bir mekanizmayla (Soft Voting) birleştirerek; bireysel modellerin yapabileceği aşırı öğrenme (overfitting) hatalarını sönümllemek ve varyansı düşük, kararlı (robust) bir tahmin sistemi oluşturmaktır.

Model	KMeans Kümeleme	Veri Durumu	MAE(Ort. Hata)	R^2 Score (Başarı)
Ridge	YOK	PCA YOK (Ham Veri)	3412.05	0.6591
Ridge	YOK	PCA VAR	3905.62	0.5834
Ridge	VAR	PCA YOK (Ham Veri)	3332.46	0.6650
Ridge	VAR	PCA VAR	3844.57	0.5898
SVR	YOK	PCA YOK (Ham Veri)	2824.16	0.6823
SVR	YOK	PCA VAR	3123.19	0.6406
SVR	VAR	PCA YOK (Ham Veri)	2818.49	0.6840
SVR	VAR	PCA VAR	3123.34	0.6412
AdaBoostRegressor	YOK	PCA YOK (Ham Veri)	1828.54	0.9141
AdaBoostRegressor	YOK	PCA VAR	1953.63	0.9032
AdaBoostRegressor	VAR	PCA YOK (Ham Veri)	1905.388	0.8928
AdaBoostRegressor	VAR	PCA VAR	2052.39	0.8937
VotingRegressor	YOK	PCA YOK (Ham Veri)	1821.12	0.8893
VotingRegressor	YOK	PCA VAR	2114.72	0.8525
VotingRegressor	VAR	PCA YOK (Ham Veri)	1936.33	0.8878
VotingRegressor	VAR	PCA VAR	2111.20	0.8533



Ridge ve SVR modellerinin 4 farklı senaryodaki performans kıyaslaması şu şekildedir:

1. Model Karşılaştırması (Ridge vs SVR):

- **Bulgu:** Tüm senaryolarda SVR, Ridge modeline göre üstünlük sağlamıştır (Base: 0.682 vs 0.659).
- **Neden:** Ridge sadece doğrusal ilişkileri modelleyebilirken; SVR, RBF çekirdeği sayesinde araç fiyatlarındaki marka-motor-yıl gibi karmaşık ve doğrusal olmayan etkileşimleri başarıyla yakalamıştır.

2. Boyut İndirgeme (PCA) Etkisi:

- **Bulgu:** PCA uygulandığında %5'lik varyans kaybına bağlı olarak performans düşüşü (SVR: -0.041) gözlemlenmiştir.
- **Değerlendirme:** Bu düşüş, eğitim süresinin kısalması ve model karmaşıklığının azalması karşılığında kabul edilebilir bir performans/hız takası (trade-off) olarak değerlendirilmiştir.

3. Kümeleme (Segmentasyon) Etkisi:

- **Bulgu:** Veriye "Pazar Segmenti" bilgisi eklendiğinde her iki model de en yüksek başarı skorlarına ulaşmıştır (SVR: 0.684).
- **Yorum:** Bu sonuç, araçların teknik özelliklerinin yanı sıra hangi pazar grubuna (Ekonomik, Lüks vb.) ait olduğu bilgisinin fiyat tahmininde kritik bir önütelik olduğunu kanıtlamıştır.

Sonuç:

Deneyler sonucunda en uygun modelin SVR, en yüksek performans sağlayan veri yapısının ise Kümeleme Destekli senaryo ($R^2=0.684$) olduğu tespit edilmiştir. PCA ise yüksek performans yerine verimlilik (hız) gerektiren durumlar için etkili bir alternatiftir.

AdaBoost ve Voting modellerinin 4 farklı senaryodaki performans kıyaslama şu şekildedir:

1. Model Karşılaştırması (AdaBoost vs Voting)

- **Beklenen Bulgu: Voting Regressor**, genellikle hem AdaBoost'tan hem de tekil SVR modelinden daha stabil ve yüksek bir skor üretecektir. AdaBoost ise SVR'ın yakaladığı karmaşıklığı yakalayabilir ancak gürültüye karşı daha hassastır.
- **Neden: * AdaBoost:** Zayıf öğrencileri (genelde sığ karar ağaçları) ardışık olarak eğitir. SVR gibi doğrusal olmayan ilişkileri çözer ancak verideki uç değerler (fiyatı çok sapan araçlar) AdaBoost'u yanıltabilir.
 - **Voting:** Ridge'in "genelleme" gücü ile SVR'ın "karmaşıklık yakalama" gücünü birleştirir. Hataları birbirini sönmeler, bu da onu en sağlam seçenek yapar.

2. Boyut İndirgeme (PCA) Etkisi

- **Bulgu:** PCA'nın AdaBoost üzerindeki negatif etkisi, Ridge'e göre daha sert olabilir. Karar ağacı tabanlı yapılar (AdaBoost'un temeli), ham haldeki "anlamlı" özellikleri (motor hacmi, marka gibi) PCA'nın soyut bileşenlerine tercih eder.
- **Değerlendirme:** Eğer veri setindeki özellik sayısı (feature count) çok yüksek değilse, AdaBoost için PCA yapmak genellikle R^2 skorunu hissedilir derecede düşürür. Ancak Voting Regressor, içindeki Ridge bileşeni sayesinde bu "bilgi kaybını" bir miktar daha iyi tolere edebilir.

3. Kümeleme (Segmentasyon) Etkisi

- **Bulgu:** Kümeleme bilgisi (Lüks, Ekonomik vb.), AdaBoost için "altın değerinde" bir özneliktir. SVR'daki başarının burada da tekrarlanması, hatta aşılması beklenir.
- **Yorum:** AdaBoost (ve ağaç tabanlı modeller), kategorik verileri ayırmada çok başarılıdır. "Pazar Segmenti" bilgisi eklendiğinde, model dallanmalarını bu segmente göre yaparak hata payını minimize eder. Voting modeli de bu yeni bilgiyi tüm alt modellerine dağıtarak en yüksek skoruna bu noktada ulaşır.