

Araç Fiyat Tahmin ve Analizi

Makine Öğrenmesi Modelleri ve Hibrit Yaklaşımlar

GitHub Linki: <https://github.com/RamazanBozkurttt/1.6Multijet-DataMiningProject-Final>

Ramazan Bozkurt

22040301027

Ömer Utku Aktemur

22040301043

Erkan Yasin Yamaan

22040301038

Veri Seti Genel Bakış

- Dosya Türü: Veri seti standart **.CSV** formatındadır.
- Kayıt Sayısı: Toplamda **~30.000 satır** araç ilanı.
- Kapsam: 18 farklı araç parametresi (sütun).
- Özellikler:
marka, model, year, price, mileage, transmission, fuelType, tax, mpg, engineSize...



Veri Tipleri Dağılımı

↑ Sayısal (Numerical)

- price: Sürekli değişken (float)
- mileage: Tam sayı (int)
- tax: Vergi tutarı (float)
- mpg: Yakıt tüketimi (float)
- engineSize: Motor hacmi (float)
- year: Araç yılı (int)

A Kategorik (Categorical)

- marka: Araç üreticisi (string)
- model: Araç modeli (string)
- transmission: Vites tipi (string)
- fuelType: Yakıt türü (string)

Kritik Ön işleme: Sütun Kayması


Ham veride saptanan yapısal bozukluklar temizlenmiştir:

- Tespit: Para birimi sembolü (£) kullanılarak yanlış sütundaki veriler saptandı.
- Onarım: Fiyatın km sütununa kaydığı satırlarda algoritmik öteleme yapılarak veri seti normalize edildi.
- Filtreleme: Model performansını bozan anlamsız ID ve metin sütunları veri setinden temizlendi.

```
if row['mileage'].contains('£'):
    row['price'] = row['mileage']
    row['mileage'] = row['tax']
    ... (Shift Left Operation)
```

Veri Hazırlama ve Pipeline

- Clustering: **K-Means** algoritması ile araç segmentasyonu ve yeni özellik üretimi.
- Ölçekleme: Uzaklık tabanlı modeller için **StandardScaler**.
- Boyut İndirgeme: Düşük varyanslı özelliklerin ayıklanması.



Topluluk Öğrenmesi (Ensemble Learning)



Neden Topluluk Yöntemleri?

Tek bir modelin hatasını azaltmak ve daha genelleyici sonuçlar elde etmek için birden fazla algoritmanın birleşimidir.

- Bagging: Paralel öğreniciler (Random Forest).
- Boosting: Hataları düzelten ardışık öğreniciler (AdaBoost, GBR).
- Stacking/Voting: Farklı türdeki modellerin oylaması.

Modellerin Kapsamlı Karşılaştırması

Sıra	Model İsmi	Maksimum R2 Skoru	MAE (TL)	En İyi Senaryo
1	StackingRegressor	0.9385	1293	Final Hibrit
2	Random Forest	0.9362	1430	Ham Veri
3	HistGradientBoosting	0.9210	1621	Kümeleme
4	GradientBoosting	0.9185	1273	Ham Veri
5	AdaBoost Regressor	0.9141	1828	Ham Veri
6	Voting Regressor	0.8894	1821	Ham Veri

Şampiyon Model: StackingRegressor


Neden En İyisi?

- Hibrit Mimari: RF, GBR ve AdaBoost modellerini "Base Learner" olarak kullanarak her birinin güçlü yanını birleştirmiştir.
- Meta-Learner: Ridge Regresyonu sayesinde alt modellerin hatalarını filtreleyerek %93.85 başarısına ulaşmıştır.
- Hata Payı: Ortalama mutlak hata (MAE) değerinde en düşük seviyeyi görmüştür.

0.938

R2 SKORU

Fiyata Etki Eden Temel Faktörler



Sayısal analizlerimize göre Şanzıman Türü belirleyen en kritik parametredir.

Kaynakça

- Pedregosa, F., et al. (2011). "Scikit-learn: Machine Learning in Python". JMLR.
- Breiman, L. (2001). "Random Forests". Machine Learning Journal.
- Chen, T., & Guestrin, C. (2016). "XGBoost: A Scalable Tree Boosting System". KDD.
- McKinney, W. (2010). "Data Structures for Statistical Computing in Python". SciPy.
- VanderPlas, J. (2016). "Python Data Science Handbook". O'Reilly Media.

Dinlediğiniz İçin Teşekkürler

Ramzan Bozkurt

22040301027

Ömer Utku Aktemur

22040301043

Erkan Yasin Yamaan

22040301038

Veri Madenciliği - 2026
